




# **PREDIKSI INDEKS KETAHANAN PANGAN (IKP) MENGUNAKAN PENDEKATAN MACHINE LEARNING REGRESI**

## **NAMA ANGGOTA:**

**NAILAH KHUSNUL M S (K1D024049)**

**ANNEKE ALYA SHANTIKA (K1D024056)**

**RIANI KURNIA AGUSTINA (K1D024059)**

**PANDU ATINI ESTIKANDARI (K1D024061)**

**Kelompok G - Machine Learning**



# LATAR BELAKANG

Ketahanan pangan merupakan aspek penting dalam pembangunan nasional Indonesia. Namun, masih terdapat kesenjangan kondisi ketahanan pangan antarwilayah yang ditunjukkan oleh variasi nilai Indeks Ketahanan Pangan (IKP) kabupaten/kota. Untuk mendukung pengambilan kebijakan yang lebih efektif, diperlukan pendekatan berbasis data yang mampu memprediksi kondisi ketahanan pangan secara akurat. Perkembangan machine learning memberikan peluang untuk membangun model prediksi IKP dengan tingkat akurasi yang tinggi. Oleh karena itu, penelitian ini menerapkan metodologi CRISP-DM untuk membangun dan membandingkan model prediksi IKP menggunakan algoritma Linear Regression, Random Forest, dan Gradient Boosting pada dataset FSVA Indonesia 2021–2024.



# RUMUSAN MASALAH

1. Bagaimana karakteristik dan hubungan antar indikator ketahanan pangan pada dataset FSVA Indonesia 2021–2024?
2. Algoritma regresi machine learning manakah yang paling efektif dalam memprediksi nilai IKP kabupaten/kota?
3. Indikator apa yang paling berpengaruh terhadap prediksi IKP berdasarkan model terbaik?
4. Bagaimana kinerja model terbaik setelah dilakukan hyperparameter tuning?

# TUJUAN

1. Menganalisis karakteristik data FSVA Indonesia 2021–2024 melalui Exploratory Data Analysis (EDA).
2. Membangun dan membandingkan algoritma Linear Regression, Random Forest, dan Gradient Boosting untuk menentukan model terbaik.
3. Mengidentifikasi indikator yang paling berpengaruh terhadap nilai IKP berdasarkan model terbaik.
4. Mengoptimalkan dan mengevaluasi kinerja model terbaik melalui hyperparameter tuning.



# SUMBER DATA

Dataset penelitian berasal dari FSVA (Food Security and Vulnerability Atlas) yang diterbitkan oleh Badan Pangan Nasional (Bapanas) bersama WFP Indonesia. Data dikumpulkan untuk periode 2021–2024 dan mencakup 514 kabupaten/kota di 34 provinsi di Indonesia, sehingga membentuk data panel yang menggambarkan kondisi ketahanan pangan secara nasional.

# DESKRIPSI DATASET

| Komponen         | Keterangan                                                                                                       |
|------------------|------------------------------------------------------------------------------------------------------------------|
| Sumber           | FSVA, Badan Pangan Nasional & WFP Indonesia ( <a href="http://www.badanpangan.go.id">www.badanpangan.go.id</a> ) |
| Jumlah Observasi | 2.056 baris                                                                                                      |
| Jumlah Kolom     | 17 kolom (14 fitur + 1 target + 2 identifikasi)                                                                  |
| Jumlah Wilayah   | 514 kabupaten/kota di 34 provinsi                                                                                |
| Periode Data     | 2021, 2022, 2023, 2024 (4 tahun)                                                                                 |
| Variabel Target  | IKP (numerik kontinu, rentang 0–100)                                                                             |
| Jenis Masalah ML | Regresi (target numerik kontinu)                                                                                 |

# INFO DATASET


| #  | Column                         | Non-Null Count | Dtype   |
|----|--------------------------------|----------------|---------|
| 0  | Tahun                          | 2056 non-null  | int64   |
| 1  | Sumber_File                    | 2056 non-null  | object  |
| 2  | Wilayah                        | 2056 non-null  | object  |
| 3  | Provinsi                       | 2056 non-null  | object  |
| 4  | Kabupaten_Kota                 | 2056 non-null  | object  |
| 5  | Komposit                       | 2056 non-null  | int64   |
| 6  | NCPR                           | 2056 non-null  | float64 |
| 7  | Kemiskinan (%)                 | 2056 non-null  | float64 |
| 8  | Pengeluaran Pangan (%)         | 2056 non-null  | float64 |
| 9  | Tanpa Listrik (%)              | 2056 non-null  | float64 |
| 10 | Tanpa Air Bersih (%)           | 2056 non-null  | float64 |
| 11 | Lama Sekolah Perempuan (tahun) | 2056 non-null  | float64 |
| 12 | Rasio Tenaga Kesehatan         | 2056 non-null  | float64 |
| 13 | Angka Harapan Hidup (tahun)    | 2056 non-null  | float64 |
| 14 | Stunting (%)                   | 2056 non-null  | float64 |
| 15 | IKP                            | 2056 non-null  | float64 |
| 16 | IKP Ranking                    | 2056 non-null  | int64   |

dtypes: float64(10), int64(3), object(4)  
memory usage: 273.2+ KB

# Missing Values


✓ Tidak ada missing values! Data sangat bersih.

## Distribusi Variabel Target IKP




Distribusi IKP memiliki rentang nilai 14,14–96,37 dengan rata-rata 73,38 dan median 77,60. Nilai skewness  $-1,74$  menunjukkan distribusi condong ke kiri, sehingga sebagian besar wilayah memiliki IKP tinggi dengan beberapa wilayah bernilai rendah. Q-Q Plot menunjukkan penyimpangan normalitas pada nilai ekstrem akibat adanya variasi antar wilayah.

## IKP Per Provinsi






# Heatmap Korelasi Antar Fitur dan IKP



Heatmap korelasi menunjukkan Komposit memiliki korelasi tertinggi dengan IKP ( $r = 0,9516$ ) sehingga berpotensi menyebabkan data leakage dan perlu dihapus. Fitur dengan hubungan kuat terhadap IKP adalah NCPR ( $r = -0,8021$ ), Kemiskinan ( $r = -0,6714$ ), Tanpa Air Bersih ( $r = -0,6533$ ), Tanpa Listrik ( $r = -0,6265$ ), dan Angka Harapan Hidup ( $r = 0,6123$ ).

## Cek Duplikat

Jumlah baris duplikat : 0  
✓ Tidak ada duplikat!



## Tangani Outlier

|                                |                      |
|--------------------------------|----------------------|
| NCPR                           | : 292 outlier di-cap |
| Kemiskinan (%)                 | : 144 outlier di-cap |
| Pengeluaran Pangan (%)         | : 35 outlier di-cap  |
| Tanpa Listrik (%)              | : 322 outlier di-cap |
| Tanpa Air Bersih (%)           | : 87 outlier di-cap  |
| Lama Sekolah Perempuan (tahun) | : 56 outlier di-cap  |
| Rasio Tenaga Kesehatan         | : 245 outlier di-cap |
| Angka Harapan Hidup (tahun)    | : 32 outlier di-cap  |
| Stunting (%)                   | : 0 outlier di-cap   |

Ukuran dataset setelah pembersihan : (2056, 14)

✓ Data bersih dan siap digunakan!

## Penentuan Objek Data

Fitur (X) : 11 kolom  
Target (y) : 2056 baris

Fitur yang digunakan:

- Tahun
- NCPR
- Kemiskinan (%)
- Pengeluaran Pangan (%)
- Tanpa Listrik (%)
- Tanpa Air Bersih (%)
- Lama Sekolah Perempuan (tahun)
- Rasio Tenaga Kesehatan
- Angka Harapan Hidup (tahun)
- Stunting (%)
- Wilayah

# Feature Scaling

Rata-rata fitur setelah scaling (harus ~0):

|                                |         |
|--------------------------------|---------|
| Tahun                          | 0.0     |
| NCPR                           | 0.0     |
| Kemiskinan (%)                 | -0.0    |
| Pengeluaran Pangan (%)         | 0.0     |
| Tanpa Listrik (%)              | 0.0     |
| Tanpa Air Bersih (%)           | 0.0     |
| Lama Sekolah Perempuan (tahun) | 0.0     |
| Rasio Tenaga Kesehatan         | -0.0    |
| Angka Harapan Hidup (tahun)    | -0.0    |
| Stunting (%)                   | 0.0     |
| Wilayah                        | 0.0     |
| dtype:                         | float64 |

Std deviasi fitur setelah scaling (harus ~1):

|                                |         |
|--------------------------------|---------|
| Tahun                          | 1.0003  |
| NCPR                           | 1.0003  |
| Kemiskinan (%)                 | 1.0003  |
| Pengeluaran Pangan (%)         | 1.0003  |
| Tanpa Listrik (%)              | 1.0003  |
| Tanpa Air Bersih (%)           | 1.0003  |
| Lama Sekolah Perempuan (tahun) | 1.0003  |
| Rasio Tenaga Kesehatan         | 1.0003  |
| Angka Harapan Hidup (tahun)    | 1.0003  |
| Stunting (%)                   | 1.0003  |
| Wilayah                        | 1.0003  |
| dtype:                         | float64 |

# Label Encoding

=== 6.1 LABEL ENCODING FITUR KATEGORIKAL ===

Encoding 'Wilayah': 514 kategori unik → numerik 0-513

✓ Label Encoding selesai!

# Feature Engineering

=== 6.3 FEATURE ENGINEERING ===

Fitur baru yang ditambahkan:

- Kemiskinan\_Stunting = Kemiskinan (%) × Stunting (%)
- AHH\_Sekolah = Angka Harapan Hidup × Lama Sekolah Perempuan (tahun)
- Air\_Listrik = Tanpa Air Bersih (%) × Tanpa Listrik (%)

Total fitur sekarang : 14



Kemiskinan\_Stunting (hasil perkalian Kemiskinan (%) × Stunting (%)) untuk merepresentasikan dampak ganda kemiskinan terhadap gizi anak, AHH\_Sekolah (hasil perkalian Angka Harapan Hidup (tahun) × Lama Sekolah Perempuan (tahun)) sebagai proksi kualitas hidup dan pendidikan secara simultan, serta Air\_Listrik (hasil perkalian Tanpa Air Bersih (%) × Tanpa Listrik (%)) untuk merepresentasikan defisit akses infrastruktur dasar secara gabungan.



# Informasi Target

=== INFORMASI TARGET ===

Nama target : IKP (Indeks Ketahanan Pangan)  
Tipe : Kontinu (Regresi)  
Rentang : 14.14 - 95.80  
Rata-rata : 73.2924  
Std deviasi : 14.5262  
Skewness : -1.7002  
Kurtosis : 3.0977



Target IKP ditetapkan sebagai variabel kontinu untuk regresi. Data training memiliki rentang 14,14–95,80, rata-rata 73,29, dan distribusi condong ke kiri dengan mayoritas nilai berada pada rentang 70–90. Q-Q Plot menunjukkan penyimpangan pada nilai ekstrem, sehingga digunakan model ensemble yang tidak bergantung pada asumsi normalitas.

## Cross Validation


Evaluasi 5-Fold CV menunjukkan Baseline tidak memiliki kemampuan prediksi ( $R^2 \approx 0$ ). Linear Regression mencapai  $R^2 = 0,8293$ , sedangkan model ensemble lebih unggul. Gradient Boosting memberikan performa terbaik ( $R^2 = 0,9779$ ) dengan stabilitas tertinggi, menunjukkan adanya hubungan non-linear antara fitur sosio-ekonomi dan IKP.

=== CROSS-VALIDATION 5-FOLD (Training Set) ===

| Model             | CV $R^2$ Mean | CV $R^2$ Std |
|-------------------|---------------|--------------|
| Baseline (Mean)   | -0.0021       | 0.0018       |
| Linear Regression | 0.8293        | 0.0306       |
| Random Forest     | 0.9692        | 0.0081       |
| Gradient Boosting | 0.9779        | 0.0038       |



# EVALUASI



=== EVALUASI PADA TEST SET ===


|                   | MAE     | RMSE    | MAPE (%) | R <sup>2</sup> |
|-------------------|---------|---------|----------|----------------|
| Gradient Boosting | 1.5779  | 2.3206  | 2.7876   | 0.9754         |
| Random Forest     | 1.6905  | 2.6953  | 3.1037   | 0.9668         |
| Linear Regression | 4.3241  | 6.6115  | 7.9131   | 0.8005         |
| Baseline (Mean)   | 10.6301 | 14.8091 | 21.6669  | -0.0009        |

Evaluasi test set menunjukkan Gradient Boosting memiliki performa terbaik dengan  $R^2 = 0,9754$ , RMSE 2,3206, dan MAE 1,5779. Random Forest berada di urutan kedua ( $R^2 = 0,9668$ ), sedangkan Linear Regression mencapai  $R^2 = 0,8005$ . Semua model ML jauh melampaui baseline, menunjukkan model mampu mempelajari pola data IKP dengan baik.


## AKTUAL VS PREDIKSI



Grafik menunjukkan nilai prediksi IKP hampir mengikuti pola nilai aktual pada 30 sampel. Selisih antara keduanya relatif kecil, terutama pada nilai IKP menengah hingga tinggi. Perbedaan hanya terlihat pada beberapa titik ekstrem, sehingga model dinilai mampu menangkap pola data dan menghasilkan prediksi yang akurat.




# SEBELUM



## Top 5 Fitur Terpenting:

|                             |          |
|-----------------------------|----------|
| NCPR                        | 0.674172 |
| Kemiskinan (%)              | 0.113862 |
| Tanpa Air Bersih (%)        | 0.111357 |
| Angka Harapan Hidup (tahun) | 0.040465 |
| AHH_Sekolah                 | 0.016090 |

# SETELAH



## Top 5 Fitur Terpenting (Tuned Model):

|                             |          |
|-----------------------------|----------|
| NCPR                        | 0.658897 |
| Kemiskinan (%)              | 0.120697 |
| Tanpa Air Bersih (%)        | 0.100596 |
| Angka Harapan Hidup (tahun) | 0.043285 |
| AHH_Sekolah                 | 0.025594 |



# PERFORMA SEMUA MODEL >>>>>>>>>>>>>>

|                           | MAE     | RMSE    | MAPE (%) | R <sup>2</sup> |
|---------------------------|---------|---------|----------|----------------|
| Gradient Boosting (Tuned) | 1.3232  | 2.2484  | 2.5506   | 0.9769         |
| Gradient Boosting         | 1.5779  | 2.3206  | 2.7876   | 0.9754         |
| Random Forest             | 1.6905  | 2.6953  | 3.1037   | 0.9668         |
| Linear Regression         | 4.3241  | 6.6115  | 7.9131   | 0.8005         |
| Baseline (Mean)           | 10.6301 | 14.8091 | 21.6669  | -0.0009        |

Urutan model dari terbaik: Gradient Boosting ( $R^2 = 0,9754$ ) → Random Forest ( $R^2 = 0,9668$ ) → Linear Regression ( $R^2 = 0,8005$ ) → Baseline ( $R^2 \approx -0,001$ ).

Gradient Boosting setelah hyperparameter tuning mencapai  $R^2 = 0,9769$ , RMSE = 2,2484, MAE = 1,3232, dan MAPE = 2,55%, performa terbaik secara keseluruhan.

## CONTOH PREDIKSI VS AKTUAL

|   | Wilayah                                | Tahun | IKP<br>Aktual | IKP<br>Prediksi | Selisih |
|---|----------------------------------------|-------|---------------|-----------------|---------|
| 0 | papua barat -<br>tambrau               | 2022  | 32.88         | 40.63           | 7.75    |
| 1 | nusa tenggara timur -<br>belu          | 2022  | 75.69         | 75.14           | 0.55    |
| 2 | maluku utara - kota<br>ternate         | 2023  | 81.32         | 78.67           | 2.65    |
| 3 | kalimantan tengah -<br>katingan        | 2024  | 77.89         | 78.96           | 1.07    |
| 4 | sulawesi tengah - tojo<br>una-una      | 2021  | 73.78         | 72.49           | 1.29    |
| 5 | jawa tengah -<br>banyumas              | 2023  | 79.02         | 79.99           | 0.97    |
| 6 | kepulauan riau - kota<br>tanjungpinang | 2023  | 74.67         | 75.13           | 0.46    |
| 7 | papua - puncak jaya                    | 2021  | 24.19         | 23.79           | 0.40    |
| 8 | banten - lebak                         | 2024  | 72.60         | 73.07           | 0.47    |

# KESIMPULAN

Berdasarkan hasil penelitian, dataset FSVA Indonesia tahun 2021–2024 memiliki kualitas data yang baik dan menunjukkan adanya perbedaan tingkat ketahanan pangan antarwilayah. Algoritma Gradient Boosting menjadi model terbaik dalam memprediksi Indeks Ketahanan Pangan (IKP) dengan nilai  $R^2$  sebesar 0,9769 dan MAPE sebesar 2,55% setelah dilakukan hyperparameter tuning. Analisis feature importance menunjukkan bahwa NCPR merupakan faktor yang paling dominan dalam memengaruhi IKP. Selain itu, model yang dihasilkan memiliki performa sangat baik tanpa indikasi overfitting, sehingga dapat digunakan sebagai pendukung pengambilan kebijakan di bidang ketahanan pangan.





# **THANK YOU**

**ANY QUESTION?**

Kelompok G  
Machine Learning