




PREDIKSI INDEKS KETAHANAN PANGAN (IKP) MENGUNAKAN PENDEKATAN MACHINE LEARNING REGRESI

NAMA ANGGOTA:

NAILAH KHUSNUL M S (K1D024049)

ANNEKE ALYA SHANTIKA (K1D024056)

RIANI KURNIA AGUSTINA (K1D024059)

PANDU ATINI ESTIKANDARI (K1D024061)

Kelompok G - Machine Learning

LATAR BELAKANG

Ketahanan pangan merupakan aspek penting dalam pembangunan nasional Indonesia. Namun, masih terdapat kesenjangan kondisi ketahanan pangan antarwilayah yang ditunjukkan oleh variasi nilai Indeks Ketahanan Pangan (IKP) kabupaten/kota. Untuk mendukung pengambilan kebijakan yang lebih efektif, diperlukan pendekatan berbasis data yang mampu memprediksi kondisi ketahanan pangan secara akurat. Perkembangan machine learning memberikan peluang untuk membangun model prediksi IKP dengan tingkat akurasi yang tinggi. Oleh karena itu, penelitian ini menerapkan metodologi CRISP-DM untuk membangun dan membandingkan model prediksi IKP menggunakan algoritma Linear Regression, Random Forest, dan Gradient Boosting pada dataset FSVA Indonesia 2021–2024.



RUMUSAN MASALAH

1. Bagaimana karakteristik dan hubungan antar indikator ketahanan pangan pada dataset FSVA Indonesia 2021–2024?
2. Algoritma regresi machine learning manakah yang paling efektif dalam memprediksi nilai IKP kabupaten/kota?
3. Indikator apa yang paling berpengaruh terhadap prediksi IKP berdasarkan model terbaik?
4. Bagaimana kinerja model terbaik setelah dilakukan hyperparameter tuning?

TUJUAN

1. Menganalisis karakteristik data FSVA Indonesia 2021–2024 melalui Exploratory Data Analysis (EDA).
2. Membangun dan membandingkan algoritma Linear Regression, Random Forest, dan Gradient Boosting untuk menentukan model terbaik.
3. Mengidentifikasi indikator yang paling berpengaruh terhadap nilai IKP berdasarkan model terbaik.
4. Mengoptimalkan dan mengevaluasi kinerja model terbaik melalui hyperparameter tuning.

SUMBER DATA

Dataset penelitian berasal dari FSVA (Food Security and Vulnerability Atlas) yang diterbitkan oleh Badan Pangan Nasional (Bapanas) bersama WFP Indonesia. Data dikumpulkan untuk periode 2021–2024 dan mencakup 514 kabupaten/kota di 34 provinsi di Indonesia, sehingga membentuk data panel yang menggambarkan kondisi ketahanan pangan secara nasional.

DESKRIPSI DATASET

Komponen	Keterangan
Sumber	FSVA, Badan Pangan Nasional & WFP Indonesia (www.badanpangan.go.id)
Jumlah Observasi	2.056 baris
Jumlah Kolom	17 kolom (14 fitur + 1 target + 2 identifikasi)
Jumlah Wilayah	514 kabupaten/kota di 34 provinsi
Periode Data	2021, 2022, 2023, 2024 (4 tahun)
Variabel Target	IKP (numerik kontinu, rentang 0–100)
Jenis Masalah ML	Regresi (target numerik kontinu)

INFO DATASET

#	Column	Non-Null Count	Dtype
0	Tahun	2056 non-null	int64
1	Sumber_File	2056 non-null	object
2	Wilayah	2056 non-null	object
3	Provinsi	2056 non-null	object
4	Kabupaten_Kota	2056 non-null	object
5	Komposit	2056 non-null	int64
6	NCPR	2056 non-null	float64
7	Kemiskinan (%)	2056 non-null	float64
8	Pengeluaran Pangan (%)	2056 non-null	float64
9	Tanpa Listrik (%)	2056 non-null	float64
10	Tanpa Air Bersih (%)	2056 non-null	float64
11	Lama Sekolah Perempuan (tahun)	2056 non-null	float64
12	Rasio Tenaga Kesehatan	2056 non-null	float64
13	Angka Harapan Hidup (tahun)	2056 non-null	float64
14	Stunting (%)	2056 non-null	float64
15	IKP	2056 non-null	float64
16	IKP Ranking	2056 non-null	int64


dtypes: float64(10), int64(3), object(4)
memory usage: 273.2+ KB

Missing Vlues

✓ Tidak ada missing values! Data sangat bersih.


Distribusi Variabel Target IKP

Distribusi Target Variable: IKP (Indeks Ketahanan Pangan)




Distribusi IKP memiliki rentang nilai 14,14–96,37 dengan rata-rata 73,38 dan median 77,60. Nilai skewness $-1,74$ menunjukkan distribusi condong ke kiri, sehingga sebagian besar wilayah memiliki IKP tinggi dengan beberapa wilayah bernilai rendah. Q-Q Plot menunjukkan penyimpangan normalitas pada nilai ekstrem akibat adanya variasi antar wilayah.

IKP Per Provinsi



Heatmap Korelasi Antar Fitur dan IKP



Heatmap korelasi menunjukkan Komposit memiliki korelasi tertinggi dengan IKP ($r = 0,9516$) sehingga berpotensi menyebabkan data leakage dan perlu dihapus. Fitur dengan hubungan kuat terhadap IKP adalah NCPR ($r = -0,8021$), Kemiskinan ($r = -0,6714$), Tanpa Air Bersih ($r = -0,6533$), Tanpa Listrik ($r = -0,6265$), dan Angka Harapan Hidup ($r = 0,6123$).

Cek Duplikat

Jumlah baris duplikat : 0

✓ Tidak ada duplikat!



Tangani Outlier

NCPR	: 292 outlier di-cap
Kemiskinan (%)	: 144 outlier di-cap
Pengeluaran Pangan (%)	: 35 outlier di-cap
Tanpa Listrik (%)	: 322 outlier di-cap
Tanpa Air Bersih (%)	: 87 outlier di-cap
Lama Sekolah Perempuan (tahun)	: 56 outlier di-cap
Rasio Tenaga Kesehatan	: 245 outlier di-cap
Angka Harapan Hidup (tahun)	: 32 outlier di-cap
Stunting (%)	: 0 outlier di-cap

Ukuran dataset setelah pembersihan : (2056, 14)

✓ Data bersih dan siap digunakan!

Penentuan Objek Data

Fitur (X) : 11 kolom
Target (y) : 2056 baris

Fitur yang digunakan:

- Tahun
- NCPR
- Kemiskinan (%)
- Pengeluaran Pangan (%)
- Tanpa Listrik (%)
- Tanpa Air Bersih (%)
- Lama Sekolah Perempuan (tahun)
- Rasio Tenaga Kesehatan
- Angka Harapan Hidup (tahun)
- Stunting (%)
- Wilayah

Feature Scaling

Rata-rata fitur setelah scaling (harus ~0):

Tahun	0.0
NCPR	0.0
Kemiskinan (%)	-0.0
Pengeluaran Pangan (%)	0.0
Tanpa Listrik (%)	0.0
Tanpa Air Bersih (%)	0.0
Lama Sekolah Perempuan (tahun)	0.0
Rasio Tenaga Kesehatan	-0.0
Angka Harapan Hidup (tahun)	-0.0
Stunting (%)	0.0
Wilayah	0.0
dtype:	float64

Std deviasi fitur setelah scaling (harus ~1):

Tahun	1.0003
NCPR	1.0003
Kemiskinan (%)	1.0003
Pengeluaran Pangan (%)	1.0003
Tanpa Listrik (%)	1.0003
Tanpa Air Bersih (%)	1.0003
Lama Sekolah Perempuan (tahun)	1.0003
Rasio Tenaga Kesehatan	1.0003
Angka Harapan Hidup (tahun)	1.0003
Stunting (%)	1.0003
Wilayah	1.0003
dtype:	float64

Label Encoding

=== 6.1 LABEL ENCODING FITUR KATEGORIKAL ===

Encoding 'Wilayah': 514 kategori unik → numerik 0-513

✓ Label Encoding selesai!

Feature Engineering

=== 6.3 FEATURE ENGINEERING ===

Fitur baru yang ditambahkan:

- Kemiskinan_Stunting = Kemiskinan (%) × Stunting (%)
- AHH_Sekolah = Angka Harapan Hidup × Lama Sekolah Perempuan (tahun)
- Air_Listrik = Tanpa Air Bersih (%) × Tanpa Listrik (%)



Total fitur sekarang : 14

Kemiskinan_Stunting (hasil perkalian Kemiskinan (%) × Stunting (%)) untuk merepresentasikan dampak ganda kemiskinan terhadap gizi anak, AHH_Sekolah (hasil perkalian Angka Harapan Hidup (tahun) × Lama Sekolah Perempuan (tahun)) sebagai proksi kualitas hidup dan pendidikan secara simultan, serta Air_Listrik (hasil perkalian Tanpa Air Bersih (%) × Tanpa Listrik (%)) untuk merepresentasikan defisit akses infrastruktur dasar secara gabungan.

Informasi Target

=== INFORMASI TARGET ===

Nama target : IKP (Indeks Ketahanan Pangan)
Tipe : Kontinu (Regresi)
Rentang : 14.14 - 95.80
Rata-rata : 73.2924
Std deviasi : 14.5262
Skewness : -1.7002
Kurtosis : 3.0977



Target IKP ditetapkan sebagai variabel kontinu untuk regresi. Data training memiliki rentang 14,14–95,80, rata-rata 73,29, dan distribusi condong ke kiri dengan mayoritas nilai berada pada rentang 70–90. Q-Q Plot menunjukkan penyimpangan pada nilai ekstrem, sehingga digunakan model ensemble yang tidak bergantung pada asumsi normalitas.


Cross Validation

Evaluasi 5-Fold CV menunjukkan Baseline tidak memiliki kemampuan prediksi ($R^2 \approx 0$). Linear Regression mencapai $R^2 = 0,8293$, sedangkan model ensemble lebih unggul. Gradient Boosting memberikan performa terbaik ($R^2 = 0,9779$) dengan stabilitas tertinggi, menunjukkan adanya hubungan non-linear antara fitur sosio-ekonomi dan IKP.

=== CROSS-VALIDATION 5-FOLD (Training Set) ===

Model	CV R^2 Mean	CV R^2 Std
Baseline (Mean)	-0.0021	0.0018
Linear Regression	0.8293	0.0306
Random Forest	0.9692	0.0081
Gradient Boosting	0.9779	0.0038

EVALUASI



=== EVALUASI PADA TEST SET ===


	MAE	RMSE	MAPE (%)	R ²
Gradient Boosting	1.5779	2.3206	2.7876	0.9754
Random Forest	1.6905	2.6953	3.1037	0.9668
Linear Regression	4.3241	6.6115	7.9131	0.8005
Baseline (Mean)	10.6301	14.8091	21.6669	-0.0009

Evaluasi test set menunjukkan Gradient Boosting memiliki performa terbaik dengan $R^2 = 0,9754$, RMSE 2,3206, dan MAE 1,5779. Random Forest berada di urutan kedua ($R^2 = 0,9668$), sedangkan Linear Regression mencapai $R^2 = 0,8005$. Semua model ML jauh melampaui baseline, menunjukkan model mampu mempelajari pola data IKP dengan baik.

AKTUAL VS PREDIKSI




Grafik menunjukkan nilai prediksi IKP hampir mengikuti pola nilai aktual pada 30 sampel. Selisih antara keduanya relatif kecil, terutama pada nilai IKP menengah hingga tinggi. Perbedaan hanya terlihat pada beberapa titik ekstrem, sehingga model dinilai mampu menangkap pola data dan menghasilkan prediksi yang akurat.





SEBELUM




Top 5 Fitur Terpenting:

NCPR	0.674172
Kemiskinan (%)	0.113862
Tanpa Air Bersih (%)	0.111357
Angka Harapan Hidup (tahun)	0.040465
AHH_Sekolah	0.016090



SETELAH



Top 5 Fitur Terpenting (Tuned Model):

NCPR	0.658897
Kemiskinan (%)	0.120697
Tanpa Air Bersih (%)	0.100596
Angka Harapan Hidup (tahun)	0.043285
AHH_Sekolah	0.025594

PERFORMA SEMUA MODEL >>>>>>>>>>>>>>

	MAE	RMSE	MAPE (%)	R ²
Gradient Boosting (Tuned)	1.3232	2.2484	2.5506	0.9769
Gradient Boosting	1.5779	2.3206	2.7876	0.9754
Random Forest	1.6905	2.6953	3.1037	0.9668
Linear Regression	4.3241	6.6115	7.9131	0.8005
Baseline (Mean)	10.6301	14.8091	21.6669	-0.0009

Urutan model dari terbaik: Gradient Boosting ($R^2 = 0,9754$) → Random Forest ($R^2 = 0,9668$) → Linear Regression ($R^2 = 0,8005$) → Baseline ($R^2 \approx -0,001$).

Gradient Boosting setelah hyperparameter tuning mencapai $R^2 = 0,9769$, RMSE = 2,2484, MAE = 1,3232, dan MAPE = 2,55%, performa terbaik secara keseluruhan.

CONTOH PREDIKSI VS AKTUAL

	Wilayah	Tahun	IKP Aktual	IKP Prediksi	Selisih
0	papua barat - tambrau	2022	32.88	40.63	7.75
1	nusa tenggara timur - belu	2022	75.69	75.14	0.55
2	maluku utara - kota terate	2023	81.32	78.67	2.65
3	kalimantan tengah - katingan	2024	77.89	78.96	1.07
4	sulawesi tengah - tojo una-una	2021	73.78	72.49	1.29
5	jawa tengah - banyumas	2023	79.02	79.99	0.97
6	kepulauan riau - kota tanjungpinang	2023	74.67	75.13	0.46
7	papua - puncak jaya	2021	24.19	23.79	0.40
8	banten - lebak	2024	72.60	73.07	0.47

KESIMPULAN

Berdasarkan hasil penelitian, dataset FSVA Indonesia tahun 2021–2024 memiliki kualitas data yang baik dan menunjukkan adanya perbedaan tingkat ketahanan pangan antarwilayah. Algoritma Gradient Boosting menjadi model terbaik dalam memprediksi Indeks Ketahanan Pangan (IKP) dengan nilai R^2 sebesar 0,9769 dan MAPE sebesar 2,55% setelah dilakukan hyperparameter tuning. Analisis feature importance menunjukkan bahwa NCPR merupakan faktor yang paling dominan dalam memengaruhi IKP. Selain itu, model yang dihasilkan memiliki performa sangat baik tanpa indikasi overfitting, sehingga dapat digunakan sebagai pendukung pengambilan kebijakan di bidang ketahanan pangan.



THANK YOU
ANY QUESTION?

Kelompok G
Machine Learning