


LAPORAN *PROJECT*
PREDIKSI INDEKS KETAHANAN PANGAN (IKP)
MENGGUNAKAN PENDEKATAN *MACHINE LEARNING* REGRESI



Anggota Kelompok G:

1. Nailah Khusul M.S (K1D024049)
2. Anneke Alya Shantika (K1D024056)
3. Riani Kurnia Agustina (K1D024059)
4. Pandu Atini Estikandari (K1D024061)

KEMENTERIAN PENDIDIKAN, KEBUDAYAAN, RISET, DAN TEKNOLOGI
UNIVERSITAS JENDERAL SOEDIRMAN
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
PROGRAM STUDI STATISTIKA
PURWOKERTO
2026

DAFTAR ISI

DAFTAR ISI.....	ii
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah.....	2
1.3 Tujuan Penelitian.....	2
1.4 Manfaat Penelitian.....	3
BAB II TINJAUAN DATASET.....	4
2.1 Sumber Data.....	4
2.2 Deskripsi Dataset.....	4
2.3 Data Dictionary.....	4
BAB III METODOLOGI.....	7
3.1 Kerangka Metodologi CRISP-DM.....	7
3.2 Eksplorasi Data (EDA).....	7
3.2.1 Statistik Deskriptif.....	7
3.2.2 Distribusi Variabel Target IKP.....	8
3.2.3 Distribusi Fitur Numerik.....	8
3.2.4 Analisis Korelasi.....	9
3.2.5 Uji Statistik.....	11
3.3.1 Penanganan Missing Values dan Duplikat.....	12
3.3.2 Deteksi dan Penanganan Outlier.....	12
3.3.3 Encoding dan Scaling.....	13
3.3.4 Penghapusan Kolom Data <i>Leakage</i>	13
3.3.5 <i>Feature Engineering</i>	13
3.3.6 Pembagian Data Train-Test.....	14
3.4 Pemodelan.....	14
BAB IV HASIL DAN PEMBAHASAN.....	15
4.1 Evaluasi Model.....	15
4.1.1 Hasil Cross-Validation 5-Fold.....	15
4.1.2 Performa pada <i>Test Set</i>	15

4.1.3 Evaluasi Visual Model Terbaik.....	16
4.2 <i>Hyperparameter Tuning</i>	17
4.3 Feature Importance.....	18
4.4 Diskusi Overfitting dan Underfitting	19
4.5 Interpretasi dan Implikasi.....	19
BAB V PENUTUP.....	21
5.1 Kesimpulan.....	21
5.2 Saran.....	21
DAFTAR PUSTAKA	23
LAMPIRAN.....	25
Lampiran 1. Statistik Deskriptif Lengkap Dataset.....	25
Lampiran 2. Penggunaan AI Assistant.....	25
Lampiran 3. Link Repository Github	25

BAB I

PENDAHULUAN

1.1 Latar Belakang

Ketahanan pangan merupakan salah satu isu fundamental dalam pembangunan nasional Indonesia. Berdasarkan definisi FAO (*Food and Agriculture Organization*), ketahanan pangan terwujud ketika seluruh penduduk pada setiap saat memiliki akses fisik, sosial, dan ekonomi terhadap pangan yang cukup, aman, dan bergizi untuk memenuhi kebutuhan dan preferensi pangan bagi kehidupan yang aktif dan sehat. Di Indonesia, kondisi ketahanan pangan dievaluasi secara periodik melalui sistem FSVA (*Food Security and Vulnerability Atlas*) yang menghasilkan Indeks Ketahanan Pangan (IKP) di tingkat kabupaten/kota sebagai acuan nasional program intervensi pangan.

Disparitas kondisi ketahanan pangan antar wilayah di Indonesia masih sangat lebar. Data FSVA 2021–2024 menunjukkan bahwa nilai IKP kabupaten/kota berkisar antara 14,14 hingga 96,37, rentang yang sangat besar mencerminkan ketimpangan akses pangan, infrastruktur, layanan kesehatan, dan kondisi sosio-ekonomi antara wilayah maju dan tertinggal. Sebagaimana ditunjukkan oleh Al Khaidar dan Boang Manalu (2025) dalam penelitian analisis ketahanan pangan nasional, perbedaan kondisi antar provinsi di Indonesia membutuhkan pendekatan berbasis data yang mampu mengidentifikasi pola dan cluster wilayah berisiko secara akurat. Pendekatan konvensional berbasis survei lapangan memerlukan waktu dan biaya yang signifikan, sehingga kemampuan memprediksi IKP berbasis data indikator yang tersedia menjadi sangat bernilai bagi pengambil kebijakan.

Perkembangan *machine learning* dalam satu dekade terakhir membuka peluang besar untuk membangun model prediktif yang mampu mengolah data tabular multivariat secara efektif. Saragih (2024) dalam penelitiannya tentang prediksi Indeks Ketahanan Pangan Indonesia menggunakan pendekatan *machine learning* membuktikan bahwa algoritma berbasis *ensemble* seperti *Random Forest* dan *eXtreme Gradient Boosting* mampu menghasilkan nilai R^2 hingga 0,91 dalam memprediksi skor ketahanan pangan, jauh melampaui metode regresi konvensional. Senada dengan hal tersebut, Fitri (2023) dalam JACOST mengonfirmasi bahwa

Gradient Boosting secara konsisten mengungguli *Linear Regression* dan *Random Forest* pada berbagai dataset sosio-ekonomi di Indonesia.

Penelitian ini mengaplikasikan metodologi CRISP-DM (*Cross-Industry Standard Process for Data Mining*) untuk membangun model prediksi IKP menggunakan dataset FSVA Indonesia 2021–2024, membandingkan tiga algoritma regresi *machine learning* (*Linear Regression*, *Random Forest*, *Gradient Boosting*), serta melakukan *hyperparameter tuning* untuk memaksimalkan akurasi prediksi.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, terdapat empat pokok permasalahan yang menjadi fokus penelitian ini:

1. Bagaimana karakteristik statistik dan distribusi data indikator ketahanan pangan dari dataset FSVA Indonesia 2021 sampai 2024, termasuk pola sebaran, anomali, dan keterkaitan antar variabel?
2. Algoritma *machine learning* regresi mana (*Linear Regression*, *Random Forest*, atau *Gradient Boosting*) yang paling efektif dalam memprediksi nilai Indeks Ketahanan Pangan (IKP) di tingkat kabupaten/kota?
3. Indikator (fitur) apa yang paling dominan memengaruhi prediksi IKP berdasarkan analisis *feature importance* dari model terbaik, dan bagaimana implikasinya terhadap kebijakan ketahanan pangan?
4. Seberapa optimal kinerja model terbaik setelah dilakukan *hyperparameter tuning*, diukur menggunakan metrik MAE, RMSE, MAPE, dan R^2 ?

1.3 Tujuan Penelitian

Mengacu pada rumusan masalah di atas, penelitian ini bertujuan untuk:

1. mengeksplorasi dan menganalisis karakteristik data FSVA Indonesia 2021 sampai 2024 melalui teknik *Exploratory Data Analysis* (EDA), mencakup statistik deskriptif, distribusi, deteksi *outlier*, dan analisis korelasi antar variabel;
2. membangun dan membandingkan tiga algoritma regresi *machine learning* (*Linear Regression*, *Random Forest*, dan *Gradient Boosting*) menggunakan *cross-validation 5-fold* dan evaluasi pada data uji untuk menentukan algoritma terbaik;

3. mengidentifikasi dan menginterpretasikan indikator paling berpengaruh terhadap IKP melalui analisis *feature importance* model terbaik sebagai dasar rekomendasi kebijakan berbasis data;
4. melakukan *hyperparameter tuning* pada model terbaik menggunakan *GridSearchCV* dan mengevaluasi akurasi prediksi secara kuantitatif menggunakan metrik MAE, RMSE, MAPE, dan R^2 ;

1.4 Manfaat Penelitian

Hasil penelitian ini diharapkan memberikan manfaat sebagai berikut:

1. memberikan gambaran pola, disparitas, dan dinamika ketahanan pangan di 514 kabupaten/kota Indonesia sebagai referensi penelitian sejenis;
2. menghasilkan panduan berbasis bukti tentang algoritma *machine learning* paling andal untuk data sosio-ekonomi wilayah di Indonesia;
3. membantu pemerintah memprioritaskan intervensi program pangan pada indikator yang memberikan dampak paling besar terhadap IKP;
4. menghasilkan model regresi *machine learning* terbaik yang berpotensi digunakan sebagai alat prediksi IKP wilayah baru dan simulasi dampak perubahan kebijakan ketahanan pangan secara kuantitatif.

BAB II

TINJAUAN DATASET

2.1 Sumber Data

Dataset yang digunakan bersumber dari FSVA (*Food Security and Vulnerability Atlas*) Indonesia yang diterbitkan secara resmi oleh Badan Pangan Nasional (Bapanas) bersama WFP (*World Food Programme*) Indonesia. FSVA merupakan sistem penilaian ketahanan pangan berbasis data yang dikumpulkan di tingkat kabupaten/kota di seluruh Indonesia dan tersedia secara publik melalui portal resmi Badan Pangan Nasional (<https://www.badanpangan.go.id>).

Pengumpulan data dilakukan untuk periode 2021 hingga 2024, mencakup empat gelombang survei tahunan. Data bersifat *longitudinal cross-sectional* (panel data) yang menggabungkan informasi dari 514 kabupaten/kota di 34 provinsi Indonesia.

2.2 Deskripsi Dataset

Tabel 1 berikut merangkum spesifikasi teknis dataset yang digunakan dalam penelitian ini.

Tabel 1. Spesifikasi Dataset FSVA Indonesia 2021–2024

Komponen	Keterangan
Sumber	FSVA, Badan Pangan Nasional & WFP Indonesia (www.badanpangan.go.id)
Jumlah Observasi	2.056 baris
Jumlah Kolom	17 kolom (14 fitur + 1 target + 2 identifikasi)
Jumlah Wilayah	514 kabupaten/kota di 34 provinsi
Periode Data	2021, 2022, 2023, 2024 (4 tahun)
Variabel Target	IKP (numerik kontinu, rentang 0–100)
Jenis Masalah ML	Regresi (target numerik kontinu)

2.3 Data Dictionary

Tabel 2 menyajikan deskripsi lengkap setiap kolom dalam dataset, mencakup tipe data, deskripsi, dan peran dalam pemodelan.

Tabel 2. Data Dictionary

No	Nama Kolom	Tipe Data	Deskripsi	Peran
1	Tahun	Integer	Tahun pengamatan (2021–2024)	Fitur

2	Sumber_File	Object	Nama file sumber (tidak informatif)	Dihapus
3	Wilayah	Kategorik	Nama kabupaten/kota (514 unik)	Fitur (encoding)
4	Provinsi	Kategorik	Nama provinsi (34 unik)	Tidak digunakan
5	NCPR	Float	Normalized Caloric Poverty Ratio — rasio kecukupan kalori	Fitur
6	Kemiskinan (%)	Float	Persentase penduduk miskin	Fitur
7	Pengeluaran Pangan (%)	Float	Persentase pengeluaran untuk pangan	Fitur
8	Tanpa Listrik (%)	Float	Persentase rumah tangga tanpa listrik	Fitur
9	Tanpa Air Bersih (%)	Float	Persentase rumah tangga tanpa air bersih	Fitur
10	Lama Sekolah Perempuan (th)	Float	Rata-rata lama sekolah perempuan ≥ 15 tahun	Fitur
11	Rasio Tenaga Kesehatan	Float	Rasio jumlah tenaga kesehatan per 1000 penduduk	Fitur
12	Angka Harapan Hidup (tahun)	Float	Angka harapan hidup saat lahir	Fitur
13	Stunting (%)	Float	Prevalensi stunting pada balita (%)	Fitur
14	IKP	Float	Indeks Ketahanan Pangan (0–100, target prediksi)	TARGET
15	IKP Ranking	Integer	Peringkat berdasarkan IKP (turunan langsung IKP)	Dihapus (leakage)
16	Komposit	Float	Skor komposit komponen IKP ($r=0,95$ vs IKP)	Dihapus (leakage)

17	Kategori	Object	Label kategori ketahanan pangan (turunan IKP)	Tidak digunakan
----	----------	--------	--	--------------------

Keterangan: merah = dihapus (leakage/tidak informatif); hijau = variabel target;
biru = fitur yang digunakan dalam pemodelan.

BAB III

METODOLOGI

3.1 Kerangka Metodologi CRISP-DM

Penelitian ini mengikuti kerangka kerja CRISP-DM (*Cross-Industry Standard Process for Data Mining*), metodologi standar industri untuk proyek *data mining* dan *machine learning*. CRISP-DM terdiri dari enam fase seperti yang diilustrasikan pada Gambar 1.



Gambar 1. Diagram Alur Metodologi CRISP-DM yang Diterapkan dalam Penelitian

Fase 1 (*Business Understanding*): mendefinisikan tujuan prediksi IKP sebagai masalah regresi. Fase 2 (*Data Understanding*): EDA melalui statistik deskriptif dan visualisasi. Fase 3 (*Data Preparation*): pembersihan data, *outlier handling*, *encoding*, *scaling*, dan *feature engineering*. Fase 4 (*Modeling*): pelatihan empat model dengan *cross-validation*. Fase 5 (*Evaluation*): evaluasi komprehensif dan *hyperparameter tuning*. Fase 6 (*Deployment*): dokumentasi dan repositori GitHub.

3.2 Eksplorasi Data (EDA)

3.2.1 Statistik Deskriptif

Analisis statistik deskriptif dilakukan untuk memahami karakteristik dasar distribusi setiap variabel. Tabel 3 menyajikan hasil statistik deskriptif variabel target IKP dan sembilan fitur numerik utama.

Tabel 3. Statistik Deskriptif Variabel Target dan Fitur Utama


Variabel	Min	Max	Mean	Median	Std Dev	Skewness
IKP (Target)	14,14	96,37	73,38	77,60	14,58	-1,74
NCPR	0,00	1,82	0,34	0,24	0,31	+1,85
Kemiskinan (%)	1,00	38,97	12,04	9,81	7,89	+1,23
Pengeluaran Pangan (%)	24,30	79,60	55,43	55,80	8,21	-0,11
Tanpa Listrik (%)	0,00	68,22	4,18	1,28	7,90	+3,42

Tanpa Air Bersih (%)	0,00	98,43	43,62	44,80	19,54	+0,07
Lama Sekolah Perempuan (th)	3,12	12,70	8,41	8,54	1,77	-0,23
Rasio Tenaga Kesehatan	0,003	0,297	0,042	0,032	0,033	+2,17
Angka Harapan Hidup (th)	54,32	77,14	68,43	68,87	3,21	-0,38
Stunting (%)	5,10	51,40	27,31	27,30	8,54	-0,05

Variabel target IKP memiliki rata-rata 73,38 dan median 77,60 dengan *skewness* negatif ($-1,74$), mengindikasikan distribusi condong ke kiri. Sebagian besar wilayah memiliki nilai IKP relatif tinggi, namun terdapat *outlier* ekstrem ke arah nilai rendah yang mencerminkan wilayah-wilayah dengan ketahanan pangan kritis.

3.2.2 Distribusi Variabel Target IKP

Gambar 2 menyajikan tiga representasi distribusi variabel target IKP: histogram, *boxplot*, dan *Q-Q Plot*.




Gambar 2. Distribusi Variabel Target IKP: Histogram, Boxplot, dan Q-Q Plot

Histogram menunjukkan sebaran IKP dengan konsentrasi nilai di rentang 70–90 dan ekor panjang ke kiri. *Boxplot* mengidentifikasi *outlier* ekstrem di bawah $Q1 - 1,5 \cdot IQR$. *Q-Q Plot* menunjukkan deviasi dari normalitas yang mengkonfirmasi hasil uji Shapiro-Wilk ($p < 0,05$). Kondisi distribusi non-normal ini menjadi justifikasi pemilihan algoritma non-parametrik (*Random Forest*, *Gradient Boosting*) sebagai model utama.

3.2.3 Distribusi Fitur Numerik

Gambar 3 menampilkan histogram distribusi untuk seluruh 9 fitur numerik yang digunakan dalam pemodelan.




Gambar 3. *Distribusi Seluruh Fitur Numerik (Merah: Mean, Oranye: Median)*

Sebagian besar fitur menunjukkan distribusi *right-skewed*, khususnya Tanpa Listrik (%), NCPR, Rasio Tenaga Kesehatan, dan Kemiskinan (%), mencerminkan ketimpangan akses infrastruktur dan layanan dasar yang nyata antar wilayah di Indonesia.

3.2.4 Analisis Korelasi


Gambar 4 menampilkan *heatmap* korelasi Pearson antar seluruh fitur numerik dan variabel target IKP.



Gambar 4. *Heatmap* Korelasi Pearson Antar Fitur dan IKP

Temuan utama: NCPR memiliki korelasi tertinggi terhadap IKP ($r = -0,80$), diikuti Kemiskinan (%) ($r = -0,67$), Tanpa Air Bersih (%) ($r = -0,65$), dan Angka Harapan Hidup ($r = +0,61$). Seluruh nilai korelasi diverifikasi menggunakan uji Spearman non-parametrik (Tabel 4) mengingat distribusi data yang non-normal.

Gambar 5 menampilkan *scatter plot* hubungan setiap fitur terhadap IKP lengkap dengan garis tren dan nilai korelasi Spearman.



Gambar 5. *Scatter Plot* Setiap Fitur terhadap IKP dengan Garis Tren dan Korelasi Spearman

3.2.5 Uji Statistik

Tabel 4 menyajikan hasil uji korelasi Spearman untuk memvalidasi signifikansi statistik hubungan antara setiap fitur dengan IKP.

Tabel 4. Hasil Uji Korelasi Spearman Fitur vs IKP

Fitur	r Spearman	p-value	Signifikan?
NCPR	-0,6113	0,000000	Ya
Tanpa Air Bersih (%)	-0,5806	0,000000	Ya
Tanpa Listrik (%)	-0,5560	0,000000	Ya
Angka Harapan Hidup (tahun)	+0,6120	0,000000	Ya
Kemiskinan (%)	-0,4639	0,000000	Ya
Rasio Tenaga Kesehatan	-0,5690	0,000000	Ya
Lama Sekolah Perempuan (tahun)	+0,4270	0,000000	Ya
Pengeluaran Pangan (%)	-0,2860	0,000000	Ya
Stunting (%)	-0,1397	0,000000	Ya

Seluruh 9 fitur menunjukkan $p\text{-value} = 0,000000$ (di bawah $\alpha = 0,05$), mengkonfirmasi bahwa semua fitur memiliki hubungan yang signifikan secara statistik dengan IKP dan layak dipertahankan dalam proses pemodelan.

3.3 Prapemrosesan & Rekayasa Fitur

3.3.1 Penanganan *Missing Values* dan Duplikat


Pemeriksaan terhadap nilai hilang (*missing values*) pada seluruh 17 kolom menunjukkan tidak terdapat satupun nilai kosong (*missing count* = 0 untuk semua kolom). Kondisi ini mengkonfirmasi kualitas pengumpulan data FSVA yang sangat baik sehingga tidak diperlukan proses imputasi apapun. Pemeriksaan *duplicate rows* juga menunjukkan hasil nol (0 baris duplikat dari 2.056 baris).

3.3.2 Deteksi dan Penanganan *Outlier*

Deteksi *outlier* dilakukan menggunakan metode IQR (*Interquartile Range*), di mana nilai di luar rentang $[Q1 - 1,5 \cdot IQR, Q3 + 1,5 \cdot IQR]$ diklasifikasikan sebagai *outlier*. Hasil deteksi disajikan pada Tabel 5.

Tabel 5. Deteksi *Outlier* Metode IQR per Fitur Numerik

Fitur	Jumlah Outlier	Persentase (%)	Metode Penanganan
NCPR	292	14,20%	Winsorizing (cap IQR)
Kemiskinan (%)	144	7,00%	Winsorizing (cap IQR)
Pengeluaran Pangan (%)	35	1,70%	Winsorizing (cap IQR)
Tanpa Listrik (%)	322	15,66%	Winsorizing (cap IQR)
Tanpa Air Bersih (%)	87	4,23%	Winsorizing (cap IQR)
Lama Sekolah Perempuan (tahun)	56	2,72%	Winsorizing (cap IQR)
Rasio Tenaga Kesehatan	245	11,91%	Winsorizing (cap IQR)
Angka Harapan Hidup (tahun)	32	1,56%	Winsorizing (cap IQR)
Stunting (%)	0	0,00%	Tidak diperlukan
IKP (Target)	178	8,66%	Dibiarkan (variasi nyata)



Gambar 7. Boxplot Deteksi *Outlier* pada Semua Fitur dan Variabel Target

Penanganan *outlier* menggunakan metode *winsorizing* (capping), yaitu menggantikan nilai di luar batas IQR dengan nilai batas tersebut. Pendekatan ini dipilih karena *outlier* pada data sosio-ekonomi wilayah umumnya merepresentasikan kondisi nyata wilayah ekstrem, bukan kesalahan pengukuran. Metode *winsorizing* mempertahankan jumlah observasi tetap 2.056 baris.

3.3.3 Encoding dan Scaling

Kolom Wilayah yang berisi 514 kategori unik dikonversi menggunakan *Label Encoding*, menghasilkan representasi numerik integer 0 hingga 513. Normalisasi fitur menggunakan *StandardScaler* (*Z-score normalization*: $z = (x - \mu) / \sigma$) diterapkan pada seluruh 11 fitur. *Scaler* di-fit hanya pada data *training* kemudian di-*transform* pada data *testing*, sesuai prinsip pencegahan *data leakage*.

3.3.4 Penghapusan Kolom Data *Leakage*

Tiga kolom dihapus sebelum pemodelan: (1) *Sumber_File* — tidak mengandung informasi prediktif; (2) *IKP Ranking* — turunan langsung *IKP* menyebabkan *data leakage*; (3) *Komposit* — skor gabungan komponen *IKP* ($r = 0,9516$) yang apabila dipertahankan akan membuat model "mengintip" nilai target selama *training*.

3.3.5 Feature Engineering

Tiga fitur interaksi baru dibuat untuk menangkap hubungan non-linear antar fitur yang relevan secara konseptual (*feature engineering*):

- $\text{Kemiskinan_Stunting} = \text{Kemiskinan (\%)} \times \text{Stunting (\%)}$ — merepresentasikan dampak ganda kemiskinan terhadap kekurangan gizi anak.

- $AHH_Sekolah = \text{Angka Harapan Hidup} \times \text{Lama Sekolah Perempuan}$ — proksi kualitas hidup dan kapasitas sumber daya manusia.
- $Air_Listrik = \text{Tanpa Air Bersih (\%)} \times \text{Tanpa Listrik (\%)}$ — merepresentasikan defisit akses infrastruktur dasar secara gabungan.

Setelah *feature engineering*, total terdapat 14 fitur yang digunakan dalam pemodelan (11 fitur asli + 3 fitur interaksi).

3.3.6 Pembagian Data Train-Test

Dataset dibagi menjadi *training set* (80%) dan *testing set* (20%) menggunakan *random split* dengan `random_state=42` untuk reproduibilitas. Pembagian ini menghasilkan 1.644 baris *training* dan 412 baris *testing*.

3.4 Pemodelan

Empat model dilatih dan dievaluasi, terdiri dari satu baseline dan tiga algoritma ML regresi: Linear Regression, Random Forest, dan Gradient Boosting. Tabel 7 menyajikan ringkasan karakteristik setiap algoritma.

Tabel 7. Ringkasan Algoritma yang Digunakan dalam Pemodelan

Model	Tipe	Konfigurasi Awal	Peran
Baseline (DummyRegressor)	Non-learner	<code>strategy=mean</code>	Acuan minimum performa
Linear Regression	Parametrik	Default sklearn	Benchmark model linear
Random Forest	Ensemble Bagging	<code>n_estimators=100</code> , <code>random_state=42</code>	Model utama kandidat 1
Gradient Boosting	Ensemble Boosting	<code>n_estimators=100</code> , <code>random_state=42</code>	Model utama kandidat 2

Evaluasi awal menggunakan *K-Fold Cross-Validation* ($k=5$) pada *training set* untuk mengestimasi generalisasi model secara robust tanpa menyentuh *test set*.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Evaluasi Model

4.1.1 Hasil Cross-Validation 5-Fold

Tabel 8 menyajikan hasil evaluasi *Cross-Validation 5-Fold* pada *training set* ($n = 1.644$) untuk seluruh model.

Tabel 8. Hasil Cross-Validation 5-Fold pada Training Set

Model	CV R ² Mean	CV R ² Std	Interpretasi
Baseline (Mean)	-0,0021	$\pm 0,0018$	Tidak ada kemampuan prediktif
Linear Regression	0,8293	$\pm 0,0306$	Performa baik, variabilitas sedang
Random Forest	0,9692	$\pm 0,0081$	Performa sangat baik, stabil
Gradient Boosting	0,9779	$\pm 0,0038$	Terbaik & paling stabil

Gradient Boosting menunjukkan CV R² Mean tertinggi (0,9779) sekaligus standar deviasi terkecil ($\pm 0,0038$), mengindikasikan model yang tidak hanya akurat tetapi juga konsisten (stabil) dalam performa di berbagai *subset* data.


4.1.2 Performa pada Test Set

Setelah *cross-validation*, seluruh model dilatih ulang pada *full training set* dan dievaluasi pada *test set* ($n = 412$). Hasil evaluasi disajikan pada Tabel 9.

Tabel 9. Perbandingan Lengkap Performa Model pada Test Set

Model	MAE	RMSE	MAPE (%)	R ²	Ranking
Baseline (Mean)	10,6301	14,8091	21,67%	-0,0009	#4 (Terburuk)
Linear Regression	4,3241	6,6115	7,91%	0,8005	#3
Random Forest	1,6905	2,6300	3,10%	0,9668	#2
Gradient Boosting	1,5779	2,3206	2,79%	0,9754	#1 (Terbaik)
GB + Tuning (Final)	1,3232	2,2484	2,55%	0,9769	#1 (Final)

Catatan: MAE = *Mean Absolute Error*; RMSE = *Root Mean Squared Error*; MAPE = *Mean Absolute Percentage Error*; R² = *Coefficient of Determination*. Nilai MAE dan RMSE dalam satuan poin IKP (skala 0–100).




Gambar 8. Perbandingan Performa Semua Model: R^2 , RMSE, MAE, dan MAPE pada *Test Set*

Gradient Boosting secara konsisten mengungguli semua model pada semua metrik evaluasi. Nilai $R^2 = 0,9754$ berarti model mampu menjelaskan 97,54% variansi IKP dari data aktual. $MAPE = 2,79\%$ menunjukkan rata-rata kesalahan prediksi hanya 2,79% dari nilai aktual IKP, yang tergolong sangat akurat ($MAPE < 5\%$ umumnya dianggap *excellent* untuk data non-stasioner) .

4.1.3 Evaluasi Visual Model Terbaik

Gambar 9 menyajikan empat visualisasi evaluasi yang menilai kualitas prediksi *Gradient Boosting* secara mendalam.



Gambar 9. Evaluasi Visual *Gradient Boosting*: (a) *Actual vs Predicted*, (b) *Aktual vs Prediksi — 30 Sampel*, (c) *Residual Plot*, (d) *Distribusi Residual*

(a) *Actual vs Predicted*: Sebagian besar titik data tersebar sangat dekat dengan garis diagonal ideal (*Perfect Prediction*), dengan dominasi warna hijau yang menandakan *error* kecil. Hanya sedikit titik berwarna merah yang mengindikasikan

error lebih besar, terutama pada nilai IKP rendah di bawah 40, menunjukkan performa prediksi yang sangat baik di hampir seluruh rentang nilai.

(b) *Aktual vs Prediksi* — 30 Sampel: Garis prediksi (merah putus-putus) mengikuti pola garis aktual (hijau) secara konsisten dari nilai IKP rendah (sekitar 22) hingga tinggi (sekitar 88). Selisih *error* yang ditunjukkan oleh garis abu-abu vertikal terlihat kecil pada sebagian besar sampel, dengan deviasi sedikit lebih besar pada beberapa sampel di rentang nilai rendah (indeks 0–5).

(c) *Residual Plot*: Residual tersebar secara acak di sekitar garis nol (merah putus-putus) tanpa membentuk pola sistematis, mengindikasikan bahwa model bebas dari *systematic bias* dan asumsi homoskedastisitas terpenuhi dengan baik.

(d) Distribusi Residual: Distribusi residual berbentuk menyerupai lonceng dengan puncak terpusat di sekitar nol, mengonfirmasi bahwa kesalahan prediksi cenderung kecil dan simetris serta tidak condong ke satu arah.

4.2 Hyperparameter Tuning

Hyperparameter tuning dilakukan pada *Gradient Boosting* menggunakan *GridSearchCV* dengan *5-fold cross-validation*. Grid parameter yang dijelajahi disajikan pada Tabel 10.

Tabel 10. Grid Parameter dan Hasil Hyperparameter Tuning

Parameter	Nilai yang Dijelajahi	Nilai Terbaik
n_estimators	[100, 200]	200
max_depth	[3, 5, 7]	5
learning_rate	[0,05; 0,1; 0,2]	0,1
subsample	[0,8; 1,0]	0,8
Best CV R ²	—	0,9814

Tabel 11. Perbandingan Performa *Gradient Boosting* Sebelum dan Sesudah Tuning


Konfigurasi	MAE	RMSE	MAPE (%)	R ²
Sebelum Tuning (default)	1,5779	2,3206	2,79%	0,9754
Sesudah Tuning (optimal)	1,3232	2,2484	2,55%	0,9769

Tuning berhasil meningkatkan performa model: MAE berkurang −16,1%, RMSE −3,1%, MAPE −8,6%, dan R² meningkat dari 0,9754 menjadi 0,9769. Peningkatan

ini mengkonfirmasi bahwa konfigurasi parameter *default* belum optimal dan proses *tuning* sistematis memberikan nilai tambah yang signifikan.

4.3 Feature Importance

Analisis *feature importance* dari model *Gradient Boosting* setelah *tuning* mengidentifikasi kontribusi relatif setiap fitur terhadap kemampuan prediktif model. Hasil disajikan pada Gambar 10.



Gambar 10. *Feature Importance — Gradient Boosting setelah Hyperparameter Tuning*

NCPR mendominasi dengan kontribusi *feature importance* 65,89%, konsisten secara konseptual karena NCPR secara langsung mengukur kecukupan asupan kalori. Kemiskinan (%) dan Tanpa Air Bersih (%) masing-masing berkontribusi ~11%, mencerminkan peran fundamental kondisi ekonomi dan akses air bersih terhadap ketahanan pangan. Fitur rekayasa AHH_Sekolah berkontribusi 1,61%, lebih tinggi dari beberapa fitur asli secara individual mengkonfirmasi keberhasilan *feature engineering* dalam menangkap pola interaksi.

4.4 Diskusi Overfitting dan Underfitting

Tabel 12 menyajikan analisis gap antara R^2 *training* dan *testing* sebagai indikator *overfitting/underfitting*.

Tabel 12. Analisis *Overfitting/Underfitting*

Model	R^2 Train	R^2 Test	Gap (Train–Test)	Status
Linear Regression	0,8389	0,8005	0,0384	Generalisasi Baik
Random Forest	0,9959	0,9668	0,0291	Generalisasi Baik
Gradient Boosting (Tuned)	0,9895	0,9769	0,0141	Generalisasi Terbaik

Ketiga model menunjukkan gap R^2 *train-test* di bawah ambang 0,1 (indikator *overfitting*). *Gradient Boosting* setelah tuning memiliki gap terkecil (0,0141), menunjukkan keseimbangan optimal antara kemampuan belajar dan generalisasi. Tidak ada model yang mengalami *underfitting* (R^2 *test* > 0,8 untuk semua model ML).

4.5 Interpretasi dan Implikasi

Berdasarkan hasil analisis *feature importance* dan korelasi, pola ketahanan pangan di Indonesia sangat dipengaruhi tiga faktor utama: (1) Kecukupan Kalori (NCPR), masalah ketahanan pangan pada dasarnya adalah masalah ketidakcukupan konsumsi kalori; (2) Kemiskinan, akses ekonomi terhadap pangan tetap menjadi hambatan utama; (3) Akses Air Bersih mencerminkan kualitas lingkungan yang mempengaruhi keamanan pangan.

Model ini dapat dimanfaatkan untuk: (a) identifikasi dini wilayah berisiko penurunan IKP berdasarkan perubahan indikator NCPR, kemiskinan, atau akses air; (b) simulasi dampak kebijakan (*policy simulation*) memperkirakan kenaikan IKP jika akses air bersih ditingkatkan; (c) alokasi prioritas intervensi program bantuan pangan ke wilayah dengan prediksi IKP terendah .

Tabel 13. Contoh Prediksi vs Aktual (20 Sampel dari *Test Set*)

No	Wilayah	Tahun	IKP Aktual	IKP Prediksi
1	Kab. Sleman	2023	88.20	87.92
2	Kab. Brebes	2022	72.40	76.51
3	Kota Makassar	2024	91.50	92.07
4	Kab. Jayawijaya	2021	35.60	38.26

5	Kab. Belu	2023	48.30	47.99
6	Kota Surabaya	2024	94.10	93.96
7	Kab. Timor Tengah Selatan	2022	41.20	42.71
8	Kab. Pidie	2021	55.70	57.35
9	Kota Bandung	2024	92.80	92.57
10	Kab. Nias Selatan	2021	29.40	24.66
11	Kab. Karanganyar	2023	85.60	85.27
12	Kota Kupang	2022	71.30	72.67
13	Kab. Alor	2021	38.90	38.95
14	Kab. Bantul	2024	87.40	88.31
15	Kota Manado	2023	88.70	89.24
16	Kab. Kepulauan Aru	2021	32.10	29.23
17	Kab. Kebumen	2022	70.80	72.57
18	Kota Pontianak	2024	84.50	83.34
19	Kab. Poso	2023	61.30	60.30
20	Kab. Sikka	2022	67.80	68.98

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan seluruh tahapan penelitian yang telah dilaksanakan, dapat ditarik kesimpulan sebagai berikut:

1. dataset FSVA Indonesia 2021 sampai 2024 memiliki kualitas sangat baik, tidak terdapat *missing values* maupun data duplikat dari 2.056 observasi di 514 kabupaten/kota. Distribusi IKP bersifat *left-skewed* dengan rata-rata 73,38 dan median 77,60, mencerminkan adanya disparitas ketahanan pangan yang signifikan antar wilayah di Indonesia;
2. algoritma *Gradient Boosting* terpilih sebagai model terbaik di antara tiga algoritma yang dibandingkan (*Linear Regression*, *Random Forest*, dan *Gradient Boosting*), dengan nilai $R^2 = 0,9754$ pada data uji sebelum *tuning* dan meningkat menjadi $R^2 = 0,9769$ setelah *hyperparameter tuning* menggunakan *GridSearchCV*. Konfigurasi optimal yang diperoleh adalah *learning_rate* = 0,1, *max_depth* = 5, *n_estimators* = 200, dan *subsample* = 0,8 dengan performa final MAE = 1,3232, RMSE = 2,2484, dan MAPE = 2,55%.
3. NCPR (*Normalized Caloric Poverty Ratio*) merupakan indikator paling dominan dengan kontribusi *feature importance* sebesar 65,89%, diikuti Kemiskinan (%) dan Tanpa Air Bersih (%) masing-masing sekitar 11%. Fitur interaksi hasil *feature engineering* yaitu AHH_Sekolah juga memberikan kontribusi lebih besar dibandingkan beberapa fitur asli secara individual;
4. model *Gradient Boosting* setelah *hyperparameter tuning* mencapai akurasi prediksi sangat tinggi dengan MAPE = 2,55% dan $R^2 = 0,9769$, artinya model mampu menjelaskan 97,69% variansi IKP. Tidak ditemukan masalah *overfitting*, ditunjukkan oleh gap R^2 *train-test* di bawah 0,04 untuk semua model.

5.2 Saran

Berdasarkan hasil penelitian dan keterbatasan yang teridentifikasi, saran untuk penelitian lanjutan adalah:

1. memperluas cakupan temporal dan menambahkan variabel seperti data produksi pertanian, harga pangan, dan indeks kerawanan iklim;

2. mengeksplorasi algoritma XGBoost, LightGBM, atau CatBoost yang umumnya menunjukkan performa lebih tinggi dari *Gradient Boosting* sklearn;
3. mengganti *Label Encoding* untuk fitur Wilayah dengan *Target Encoding* atau memasukkan koordinat geografis untuk menangkap efek spasial;
4. mengintegrasikan pendekatan *Geographically Weighted Regression* (GWR) untuk menangkap ketergantungan spasial antar kabupaten;
5. membangun antarmuka web (*dashboard*) menggunakan *Streamlit* untuk memungkinkan simulasi prediksi IKP secara *real-time* bagi pengambil kebijakan.

DAFTAR PUSTAKA

- Al Khaidar, & Boang Manalu, F. A. (2025). *Implementasi Unsupervised Learning untuk Analisis Ketahanan Pangan Nasional Menggunakan Metode Density-Based Spatial Clustering of Applications with Noise*. IMPROVE: Jurnal Teknologi Informasi dan Rekayasa Komputer, 17(2). <https://ejurnal.ulbi.ac.id/index.php/improve/article/view/4556>
- Amhar, R., Musaruddin, M., & Saputra, R. A. (2024). *Implementasi Ensemble Learning Metode XGBoost dan Random Forest untuk Prediksi Waktu Penggantian Baterai Aki*. BIOS: Jurnal Teknologi Informasi dan Rekayasa Komputer, 5(2), 111–119. <https://doi.org/10.37148/bios.v5i2.128>
- Anugraha, Y. S. (2026). *Model Prediksi Produktivitas Padi Menggunakan XGBoost dan Random Forest*. Jurnal Sistem Informasi dan Informatika (JSII), LPPM Universitas Banten Jaya. <https://ejournal.lppm-unbaja.ac.id/index.php/jsii/article/view/4169>
- Arifin, M., & Sulisty, A. (2024). *Analisis Komparatif Linear Regression, Random Forest, dan Gradient Boosting untuk Prediksi Banjir*. Jurnal Pendidikan dan Teknologi Indonesia (JPTI). <https://jpti.journals.id/index.php/jpti/article/view/599>
- Fitri, E. (2023). *Analisis Perbandingan Metode Regresi Linier, Random Forest Regression dan Gradient Boosted Trees Regression Method untuk Prediksi Harga Rumah*. Journal of Applied Computer Science and Technology (JACOST), 4(1), 58–64. <https://journal.isas.or.id/index.php/JACOST/article/view/491>
- Khaidir, Fadhliani, Wirda, Z., & Ramadhani, A. (2025). *Model Prediksi Produksi Pertanian Berbasis Machine Learning dan Data Lapangan*. SISFO: Jurnal Ilmiah Sistem Informasi, 9(2), 172–182. <https://ojs.unimal.ac.id/sisfo/article/view/26015>
- Nizami, A. (2024). *Analisis Kinerja Model Machine Learning dalam Prediksi Gagal Panen Gabah*. Progresif: Jurnal Ilmiah Komputer, STMIK Banjarbaru. <https://ojs.stmik-banjarbaru.ac.id/index.php/progresif/article/view/2501>

- Saragih, R. (2024). *Analysis of Food Security Index Predictions in Indonesia using Machine Learning Approach*. Agro Bali: Agricultural Journal, Universitas Panji Sakti. <https://ejournal.unipas.ac.id/index.php/Agro/article/view/2302>
- Sumarlin, S., et al. (2025). *Data Mining Pendidikan: Prediksi Gaya Belajar Mahasiswa Menggunakan Algoritma Machine Learning*. Jurnal Teknologi Informasi dan Ilmu Komputer (JTIK), Universitas Brawijaya. <https://jtiik.ub.ac.id/index.php/jtiik/article/view/9190>
- Hermawati, S., & Santoso, B. (2024). *Prediksi Kualitas Air Menggunakan Metode Random Forest dan Gradient Boosting*. Khatulistiwa Informatika: Jurnal Ilmu Komputer dan Teknologi Informasi, AMIK BSI. <https://ejournal.bsi.ac.id/index.php/khatulistiwa/article/view/16004>

LAMPIRAN

Lampiran 1. Statistik Deskriptif Lengkap Dataset

Variabel	Count	Mean	Std	Min	Q1	Median	Q3	Max
IKP	2056	73,38	14,58	14,14	69,25	77,60	82,96	96,37
NCPR	2056	0,34	0,31	0,00	0,11	0,24	0,47	1,82
Kemiskinan (%)	2056	12,04	7,89	1,00	6,14	9,81	15,99	38,97
Peng. Pangan (%)	2056	55,43	8,21	24,30	49,98	55,80	61,16	79,60
Tanpa Listrik (%)	2056	4,18	7,90	0,00	0,31	1,28	4,45	68,22
Tanpa Air Bersih (%)	2056	43,62	19,54	0,00	28,93	44,80	57,68	98,43
Lama Sekolah Perempuan	2056	8,41	1,77	3,12	7,19	8,54	9,72	12,70
Rasio Tenaga Kesehatan	2056	0,042	0,033	0,003	0,020	0,032	0,053	0,297
AHH (tahun)	2056	68,43	3,21	54,32	66,62	68,87	70,69	77,14
Stunting (%)	2056	27,31	8,54	5,10	21,50	27,30	33,20	51,40

Lampiran 2. Penggunaan AI Assistant

<https://chatgpt.com/share/6a3b9891-7284-83ec-acc2-299d7da48b9c>

<https://chatgpt.com/share/6a3b95d5-bb38-83ec-9174-5138eb0a1662>

<https://chatgpt.com/share/6a3b9d4c-3810-83ec-bb5b-0faade7c92d4>

<https://chatgpt.com/share/6a3b9d6b-a7d0-83ec-a3b1-87af1b9c6e98>

Lampiran 3. Link Repository Github

<https://github.com/annekeshantika-a11y/ml-project-ketahanan-pangan>